

**Министерство науки и высшего образования Российской Федерации**  
**ФГАОУ ВО «УрФУ имени первого Президента России Б.Н. Ельцина»**  
Кафедра «школы бакалавриата (школа)»

Оценка работы \_\_\_ 100 \_\_\_

Руководитель от УрФУ Кошелев А.А.

Тема задания на практику

Методы решения дифференциальных уравнений на основе искусственных  
нейронных сетей.

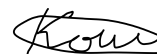
**ОТЧЕТ**

Вид практики Производственная практика

Тип практики Производственная практика, Научно-исследовательская работа

Руководитель практики от предприятия (организации) Кошелев АА

ФИО руководителя      Подпись



Студент Кузнецов И.А.

ФИО студента

Специальность (направление подготовки) 01.03.01 Математика

Группа МЕН-490102

Екатеринбург 2023

# РЕФЕРАТ

Кузнецов Игорь александрович «Возможность использования искусственных нейронных сетей для решения задач математической физики»: работа содержит: страниц 18, иллюстраций 5, использованных источников 11

Ключевые слова: PINN, дифференциальные уравнения, электрокинетика, нейронные сети, python

PINN (Physics-Informed Neural Networks) - это метод, который сочетает в себе преимущества нейронных сетей и физических моделей для решения задач научного моделирования. В данном дипломном проекте исследуется применение метода PINN для решения задачи обратной задачи электрокинетики. В работе проводится анализ эффективности метода PINN в сравнении с классическими методами решения обратных задач. Также исследуется влияние различных параметров на точность решения задачи. Результаты исследования показывают, что метод PINN может быть эффективным инструментом для решения задач научного моделирования, особенно в случаях, когда классические методы неэффективны или недостаточно точны. Были использованы следующие технологии:

- язык программирования Python;
- библиотека для работы с глубокими нейронными сетями Tensorflow;
- библиотека ESPResSo, для проведения традиционных симуляций;

# Содержание

<b>РЕФЕРАТ</b>	<b>2</b>
<b>1 Введение</b>	<b>4</b>
<b>2 Постановка задачи</b>	<b>6</b>
2.1 Цель работы . . . . .	6
2.2 Описание задачи . . . . .	6
<b>3 Используемые технологии</b>	<b>7</b>
<b>4 Теоретическое описание PINN</b>	<b>8</b>
<b>5 Техническая реализация</b>	<b>10</b>
<b>6 Эксперименты</b>	<b>11</b>
6.1 Установившееся распределение тепла в кольце . . . . .	11
6.2 Задача электрокинетики . . . . .	13
6.3 Упрощённый случай . . . . .	14
6.4 Полный случай . . . . .	15
<b>7 Заключение</b>	<b>16</b>
<b>8 Список литературы</b>	<b>17</b>

# 1 Введение

В последние годы нейронные сети получили широкое распространение, они широко используются для анализа и генерации изображений и видео, обработки естественных языков (перевод, чат-боты), медицинской диагностики, финансовых прогнозах и так далее.

Одним из перспективных направлений в этой области являются так называемые PINN – Physics-Informed Neural Networks, физически-информированные нейронные сети. Классические нейронные сети используют большую выборку реальных данных, однако в естественно-научных областях, таких как физика, химия, биология и т.д. зачастую может просто не хватать нужного объёма данных для обучения. PINN способны обойти это ограничения, используя в обучении знания законов физики, описываемые дифференциальными уравнениями в частных производных. Это позволяет использовать неполные и зашумленные данные, что делает их полезными в реальных научных задачах. Однако, вычислительная сложность PINN выше, чем у классических нейронных сетей, что требует большого количества вычислительных мощностей.

Впервые термин PINN был введён в статье [1]. В ней автор дал формальное определение PINN'ам и рассмотрел решение нескольких задач: уравнение Шрёдингера, Навье-Стокса, Ален-Чана.

В настоящее время PINN широко применяются моделировании, анализе широкого спектра физических явлений:

В статье [2] рассматривается задача симуляции циклической вольтаметрии, исследователями было рассмотрено несколько случаев: одномерная вольтаметрия на дисковом электроде с полубесконечными или тонкослойными граничными условиями, двумерная вольтаметрия на микрополосковом электроде и наконец вольтаметрия на края квадратного электрода, количественно определяя неравномерное распределение тока вблизи угла электрода. Для моделирования был использован перцептрон использующий от трёх до шести скрытых слоёв, и гиперболический тангенс в качестве функции активации. Полученные исследователями данные хорошо согласуются с решениями этих же задач, полученными

другими способами.

Так же PINN применяются для: анализа литий-ионных батарей [3, 4], для моделирование теплопереноса в системах со сложной геометрией [5, 6], решения уравнения Навье-Стокса для моделирования турбулентности [7], химической кинематике [8, 9]. Для изучения биологических процессов существует разновидность PINN'ов – BINN (Biologically-informed neural network) [10]

## **2 Постановка задачи**

### **2.1 Цель работы**

Рассмотреть уже решённую физическую задачу, решить её с помощью PINN и сравнить полученные данные с изначальным решением, оценить целесообразность применения PINN к задаче.

### **2.2 Описание задачи**

На вход нейросети подаются пространственно-временные координаты. На выходе хотим получить различные характеристики исследуемого физического процесса.

### 3 Используемые технологии

Для разработки будем использовать язык Python 3.10.6 – высокоуровневый язык программирования общего назначения, один из наиболее популярных языков в области машинного обучения и Tensorflow – библиотеку для создания и обучения нейронных сетей. Выбор данной библиотеки обусловлен простотой создания нейронных сетей, высокой производительностью, а так же встроенным автоматическим дифференцированием, которое и позволит нам обучить нейросеть дифференциальными уравнениями в частных производных.

## 4 Теоретическое описание PINN

Пусть система описывается некой системой дифференциальных уравнений:

$$F_j(t, x, u, \lambda_j) = 0, x \in \Omega, t > 0, j = \overline{1, N} \quad (1)$$

где  $t$  – время,  $x$  – пространственные координаты,  $\Omega$  – некоторая область в пространстве  $\mathbb{R}^n$ ,  $u(t, x)$  – искомая функция описывающая интересующие нас свойства системы (скорость, концентрация, потенциал и т.п.),  $\lambda_j$  – векторы постоянных параметров системы, такие как плотность вещества, заряд частиц, теплопроводность материала, температура окружающей среды и тому подобное.

Определим  $f(t, x)$  следующим образом:

$$f(t, x) := \begin{pmatrix} F_1(t, x, u) \\ F_2(t, x, u) \\ \dots \\ F_N(t, x, u) \end{pmatrix} \quad (2)$$

где  $u(t, x)$  аппроксимируется с помощью глубокой нейронной сети.  $f(t, x)$  назовём физически-информированной нейросетью, или же PINN, она может быть получена с помощью автоматического дифференцирования сложных функций. Данная имеет все те же параметры, что и сеть  $u(t, x)$ , а так же дополнительно набором параметров  $\lambda$ .

Для обучения нейросети составим следующую функцию потерь:

$$MSE = MSE_f + MSE_u \quad (3)$$

где

$$MSE_f = \sum_{j=1}^N \frac{1}{N_f} \sum_{i=1}^{N_f} F_j^2(t_f^i, x_f^i, u(t_f^i, x_f^i)) \quad (4)$$

требует соблюдения дифференциальных уравнений, описывающих процесс, здесь  $\{t_f^i, x_f^i\}_{i=1}^{N_f}$  – точки коллокации для  $F_j$ ,  $N_f$  – количество этих



точек и

$$MSE_u = \frac{1}{N_u} \sum_{i=1}^{N_u} ((u(t_u^i, x_u^i)) - u_0^i)^2 \quad (5)$$

требуется соблюдения экспериментальных данных и/или граничных условий  $(t_0^i, x_0^i, u_0^i)_{i=1}^{N_0}$  для функции  $u(t, x)$ .

## 5 Техническая реализация

В качестве архитектуры нейронной сети, аппроксимирующей функцию  $u(t, x)$  возьмём многослойный перцептрон, точное число слоёв и нейронов в каждом слое будем выбирать экспериментально, в качестве функции активации слоя будем использовать  $\tanh$ . Для создания нейронной сети воспользуемся классом `tensorflow.keras.Model`, для создания слоёв классом `tensorflow.keras.layers.Dense`. PINN  $f(t, x)$  будет иметь всего один слой. Параметрами этого слоя и есть параметры  $\lambda_j$  из 1. Внутри этого слоя мы считаем частные производные  $u(t, x)$  с помощью `tensorflow.GradientTape`, и составлять из них и параметров  $\lambda_j$  систему уравнений 1. На выход из данного слоя будем выдавать значения  $u(t, x)$  и сами эти уравнения. В силу вида системы 1 все выходы, соответствующие уравнениям системы 1 должны быть равны 0. В качестве оптимизатора будем использовать Adam, а в качестве метрики MSE

## 6 Эксперименты

### 6.1 Установившееся распределение тепла в кольце

Рассмотрим для начала относительно простую задачу: определить распространение тепла, установившееся в кольце  $1 < r < 2$ .  $0 < \phi < 2\pi$ , с граничными условиями:

$$\begin{aligned} u(1, \phi) &= \cos \phi + \sin \phi + \sin(2\phi) + 5 \sin(3\phi) + 1 \\ u(2, \phi) &= \sin(2\phi) + \sin(3\phi) + \cos(4\phi) \end{aligned} \quad (6)$$

Установившееся распространение тепла описывается уравнением Пуассона, учитывая что внутренних источников тепла нет получаем:

$$\Delta u = 0 \quad (7)$$

Для полярных координат оно принимает вид

$$\frac{\partial^2 u}{\partial r^2} + \frac{1}{r} \frac{\partial u}{\partial r} + \frac{1}{r^2} \frac{\partial^2 u}{\partial \phi^2} = 0 \quad (8)$$

Аналитическое решение данной задачи:

$$\begin{aligned} u(r, \phi) &= 1 - \frac{\ln r}{\ln 2} \\ &+ \left( \frac{-r}{3} + \frac{4}{3r} \right) \sin(\phi) + \left( \frac{-r}{3} + \frac{4}{3r} \right) \cos(\phi) \\ &+ \left( \frac{r^2}{5} + \frac{4}{5r^2} \right) \sin(2\phi) \\ &+ \left( \frac{3r^3}{63} + \frac{312}{64r^3} \right) \sin(3\phi) \\ &+ \left( \frac{16r^4}{255} - \frac{16}{255r^4} \right) \cos(4\phi) \end{aligned} \quad (9)$$

В данном случае функция потерь будем выглядеть следующим образом:

$$\begin{aligned}
MSE = & \frac{1}{N_f} \sum_{i=1}^{N_f} \left( \frac{\partial^2 u}{\partial r^2}(r_i, \phi_i) + \frac{1}{r} \frac{\partial u}{\partial r}(r_i, \phi_i) + \frac{1}{r^2} \frac{\partial^2 u}{\partial \phi^2}(r_i, \phi_i) \right)^2 + \\
& \frac{1}{N_u} \sum_{i=1}^{N_u} (u(1, \phi_i) - \cos \phi + \sin \phi + \sin(2\phi_i + 5 \sin(3\phi_i + 1))^2 + \\
& \frac{1}{N_u} \sum_{i=1}^{N_u} (u(2, \phi_i) - \sin(2\phi_i + \sin(3\phi_i + \cos(4\phi_i))^2
\end{aligned} \quad (10)$$

Запустим обучение со следующими конфигурациями скрытых слоёв:

- 20, 20, 20
- 50, 50, 50

Для одной итерации обучения возьмём по одной точке для каждого граничного условия 10 и одну внутреннюю точку для уравнения 9, всего 3 точки на итерацию. Рассмотрим случаи с 1000, 10000 и 100000 точек. Обучать будем в течении 1000 эпох или пока ошибка не будет улучшаться в течении 10 эпох хотя бы на 0.0001, размер батча 32. Результаты обучения изображён на рисунке 1, время обучения указано в таблице 1

Слои \ Итераций	Итераций		
	1000	10000	100000
[20, 20, 20]	10.06	85.62	401.14
[50, 50, 50]	12.68	51.69	173.97

Таблица 1. Время обучения в секундах




Рис. 1. График loss-функции числа в квадратных скобках – слои, последнее число – количество эпох

## 6.2 Задача электрокинетики

Для примера возьмём систему из [11]. Она описывается следующими уравнениями

$$\begin{aligned}
 \vec{j} &= -D\nabla c - \xi z e c \nabla \Phi + c \vec{u} \\
 \partial_t c &= -\nabla \cdot \vec{j} \\
 \nabla^2 \Phi &= -4\pi l_B k_B T z c \\
 \rho(\partial_t \vec{u} + (\vec{u} \cdot \nabla) \vec{u}) &= -\nabla p_H + \eta \nabla^2 \vec{u} - (k_B T \nabla c + z e c \nabla \Phi) \\
 \nabla \cdot \vec{u} &= 0
 \end{aligned}$$

Здесь первое уравнение в системе описывает поток плотности, второе электростатику, третье гидродинамику с помощью уравнения Навье-Стокса, четвёртое уравнение несжимаемости жидкости.

Рассмотрим систему щелевых пор, состоящую из двух одноимённо

заряженных бесконечных пластин. Выпишем для такой системы граничные условия

$$\begin{aligned}
c(t, X_l) &= 0.01 \\
c(t, X_r) &= 0.01 \\
c(0, X) &= 0.002 \\
\vec{v}(t, X_l) &= 0 \\
\vec{v}(t, X_r) &= 0 \\
\vec{v}(0, X) &= 0 \\
\Phi(t, X_l) &= -0.05 \\
\Phi(t, X_r) &= -0.05 \\
\Phi(0, X) &= -0.009x^2 + 2
\end{aligned}$$

здесь  $t$  – время,  $X_l$  – пространственные координаты, соответствующие левой стенке,  $X_r$  – правой,  $x$  в формул для  $\Phi(0, x)$  соответствует оси, перпендикулярной пластинам.

### 6.3 Упрощённый случай

В начале рассмотрим упрощённую систему уравнений с одной пространственной координатой и без скорости

$$\begin{aligned}
\frac{dc}{dT} &= -\nabla \cdot (-D\nabla c - \xi zec\nabla\Phi) \\
\nabla^2\Phi &= -4\pi l_B k_B T c
\end{aligned}$$

С граничными условиями

$$\begin{aligned}
\frac{dc}{dX}(t, 0) &= 0 \\
\frac{dc}{dX}(t, 1) &= 0 \\
c(0, X) &= 1 \\
\Phi(0) &= 1 \\
\Phi(1) &= 1
\end{aligned}$$

Координаты в данном случае нормализованны

$$T = t/t_{\max}, \quad X = (x + x_{\min})/x_{\max}$$

где  $t_{\max}$  – время симуляции,  $x_{\max}$  – размер системы по  $x$ -овой координате,  $x_{\min}$  – координата левой стенки. Оператор  $\nabla$  действует по пространственным координатам  $\nabla = (\frac{d}{dX})$ , все константы положим равными 1 и исключим  $4\pi$  из второго уравнения.

Запустим обучение следующим образом: 100 запусков обучения (функция `fit`) по 10 эпох на 10000 наборах точек (внутренняя, граничная и начальная). Обучение заняло 2 минуты 48 секунд, значение функции потерь:  $1.7378 \cdot 10^{-5}$ . Результаты симуляции представлены на рис. 2 3:




Рис. 2. Упрощённый случай: концентрация

## 6.4 Полный случай

Рассмотрим двумерный случай. Скрытые слои будут иметь размеры 80 и 40, входной слой 4, один для концентрации, два для скорости и один для потенциала, функция активации  $\tanh$  (гиперболический тангенс). Результат работы после 5000000 итераций показан на графике 4

Рассмотрим теперь трёхмерный случай. Скрытые слои так же будут иметь размеры 80 и 40, входной слой 5, один для концентрации, три для скорости и один для потенциала, функция активации  $relu$ . Результат работы после 30000000 итераций показан на графике 5




Рис. 3. Упрощённый случай: потенциал




Рис. 4

## 7 Заключение

Мы написали и протестировали PINN, который решает задачу электрокинетики о системе щелевых пор, состоящих из двух одноимённо заряженных бесконечных пластин. На данном этапе не удалось достичь достаточно точных результатов. Связанно это может быть как со сложностью самих исходных уравнений, так и с недостаточным временем обучения модели. Так же возможно что при задании уравнений была допущена ошибка.



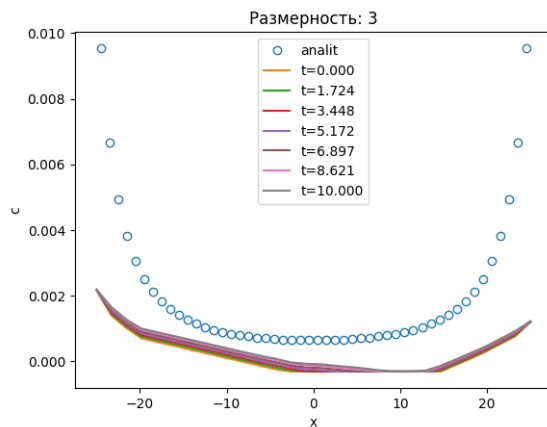


Рис. 5

## 8 Список литературы

- [1] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics informed deep learning (part i): Data-driven solutions of nonlinear partial differential equations, 2017.
- [2] Haotian Chen, Enno Kätelhön, and Richard G. Compton. Predicting voltammetry using physics-informed neural networks. *The Journal of Physical Chemistry Letters*, 13(2):536–543, 2022. PMID: 35007069.
- [3] Muratahan Aykol, Chirranjeevi Balaji Gopal, Abraham Anapolsky, Patrick K. Herring, Buis van Vlijmen, Marc D. Berliner, Martin Z. Bazant, Richard D. Braatz, William C. Chueh, and Brian D. Storey. Perspective-combining physics and machine learning to predict battery lifetime. *Journal of the Electrochemical Society*, 168(3), 2021.
- [4] Renato G. Nascimento, Matteo Corbetta, Chetan S. Kulkarni, and Felipe A. C. Viana. Hybrid physics-informed neural networks for lithium-ion battery modeling and prognosis. *Journal of Power Sources*, 1(513), 2021.
- [5] Navid Zobeiry and Keith D. Humfeld. A physics-informed machine learning approach for solving heat transfer equation in advanced manufacturing and engineering applications. *Engineering Applications of Artificial Intelligence*, 101:104232, 2021.

- [6] Shengze Cai, Zhicheng Wang, Sifan Wang, Paris Perdikaris, and George Em Karniadakis. Physics-Informed Neural Networks for Heat Transfer Problems. *Journal of Heat Transfer*, 143(6), 04 2021. 060801.
- [7] Fabian Pioch, Jan Hauke Harmening, Andreas Maximilian Müller, Franz-Josef Peitzmann, Dieter Schramm, and Ould el Moctar. Turbulence modeling for physics-informed neural networks: Comparison of different rans models for the backward-facing step flow. *Fluids*, 8(2), 2023.
- [8] Weiqi Ji, Weilun Qiu, Zhiyu Shi, Shaowu Pan, and Sili Deng. Stiff-pinn: Physics-informed neural network for stiff chemical kinetics. *The Journal of Physical Chemistry A*, 125(36):8098–8106, 2021. PMID: 34463510.
- [9] Gabriel S. Gusmão, Adhika P. Retnanto, Shashwati C. da Cunha, and Andrew J. Medford. Kinetics-informed neural networks. *Catalysis Today*, 2022.
- [10] John H. Lagergren, John T. Nardini, Ruth E. Baker, Matthew J. Simpson, and Kevin B. Flores. Biologically-informed neural networks guide mechanistic modeling from sparse experimental data, 2020.
- [11] Jean-Noël Grad. Electrokinetics.